

DTRS: Document Translation and Reconstruction System

DLEGOREAM LABORATORY



문제인식: 문서스캔은 편리하지만 용량이크고 화질이 안좋다는 문제가있다 화질을 아무리 높여도 원본, 벡터형식의 느낌은 안난다

해결: 스캔문서를 벡터형식으로 변환한다





DLEGOREAM
— LABORATORY —

초록 (Abstract)

기존 OCR 기반 문서 번역 시스템은 텍스트 내용을 다른 언어로 변환할 수 있으나, 번역 과정에서 폰트, 표, 수식, 그래프 및 문서 레이아웃 정보가 손실되는 문제가 존재한다. 이러한 문제는 원본 문서의 시각적 구조와 정보 전달력을 저하시켜 번역 결과물의 활용성을 제한한다.

본 연구에서는 문서 구조 보존형 번역 프레임워크인 DTRS(Document Translation and Reconstruction System)를 제안한다. DTRS는 OCR, 문서 구조 분석, 폰트 추정, 표 인식, 수식 재구성, 배경 복원 및 레이아웃 적응 알고리즘을 통합하여 원본 문서의 시각적 구조를 유지한 상태로 다국어 번역을 수행한다.

제안된 시스템은 문서를 단순한 텍스트 집합이 아닌 구조적·시각적 객체의 집합으로 해석하며, 번역 이후에도 원본과 유사한 형태의 문서를 자동 생성하는 것을 목표로 한다. 이를 통해 기존 OCR 기반 번역 시스템의 한계를 극복하고, 고품질 문서 재구성형 번역 환경을 제공할 수 있다.



1. 서론

최근 OCR 기술과 대규모 언어 모델의 발전으로 이미지 문서 및 PDF 문서의 자동 번역이 가능해지고 있다. 그러나 대부분의 기존 시스템은 문서를 텍스트 중심으로 처리하며, 번역 과정에서 다양한 시각적 정보가 손실된다.

일반적인 OCR 번역 과정은 다음과 같다.

문서 입력



OCR



번역



텍스트 출력

이 과정에서는 다음과 같은 문제가 발생한다.

원본 폰트 정보 손실
표 구조 붕괴
수식 왜곡
그래프 정보 손실
이미지 내부 텍스트 제거 실패
문서 레이아웃 붕괴

따라서 본 연구는 의미적 번역뿐 아니라 문서 구조와 시각적 형태까지 보존하는 문서 재구성형 번역 시스템을 제안한다.

2. 시스템 개요

DTRS는 문서를 구조적 객체의 집합으로 해석한다.

각 객체는 다음과 같은 유형으로 분류된다.

Text Object

Table Object

Equation Object

Graph Object

Image Object

Layout Object



시스템은 객체 단위 분석을 수행한 후 번역 결과를 동일한 구조로 재배치한다.

전체 파이프라인은 다음과 같다.

문서 입력



OCR



문서 구조 분석



텍스트 메타데이터 추출



폰트 추정



표 분석



수식 분석



텍스트 제거



배경 복원



번역



레이아웃 적응



문서 재구성



최종 문서 생성



3. 텍스트 객체 추출

OCR 엔진은 텍스트와 위치 정보를 추출한다.

각 텍스트 객체는 다음과 같이 저장된다.

json



```
{  
  "text": "Hello",  
  "x": 100,  
  "y": 200,
```

```
"rotation": 0,  
"color": "#000000"  
}
```

이를 통해 원본 문서의 위치 및 시각적 속성을 유지할 수 있다.

4. 폰트 크기 추정 알고리즘

기존 OCR 시스템은 Bounding Box 높이를 기반으로 폰트 크기를 추정한다.

그러나 Bounding Box는 여백을 포함하기 때문에 실제 문자 크기를 정확하게 반영하지 못한다.

본 연구에서는 실제 문자 픽셀 높이를 이용한 폰트 크기 추정 방식을 제안한다. 절차는 다음과 같다.

문자 영역 추출

이미지 이진화

최상단 검은 픽셀 탐색

최하단 검은 픽셀 탐색

문자 높이 계산



문자 높이는 다음과 같이 계산된다.

문자높이 = 하단픽셀좌표 - 상단픽셀좌표

이를 통해 실제 글자 크기에 가까운 폰트 크기를 추정할 수 있다.

5. 문자 폭 및 간격 복원

번역 이후 원본 레이아웃을 유지하기 위해 문자 시작 좌표를 기록한다.

예를 들어 다음과 같은 좌표가 존재한다고 가정한다.

A = 100

B = 118

C = 136

이 경우 A의 폭은 다음과 같이 추정된다.

폭 = B좌표 - A좌표

이를 통해 문자 간격과 정렬 구조를 복원할 수 있다.

6. 폰트 추정 인공지능

텍스트 이미지가 입력되면 폰트 분류 모델이 동작한다.

입력:

HELLO

출력:

Arial (93%)

또는

Noto Sans (89%)

예측 결과는 문서 재구성 단계에서 사용된다.

이를 통해 원본 문서와 유사한 시각적 표현을 재현할 수 있다.



7. 표 재생성 시스템

표는 텍스트가 아닌 구조 객체로 저장된다.

표 객체는 다음과 같은 형태를 가진다.

표의 기준은 사각형안에 글자가 있고 선이 있다는걸 기준으로 추정한다

json

```
{
  "type": "table",
  "rows": 4,
  "cols": 3,
  "cells": []
}
```



번역 이후에도 동일한 행·열 구조를 유지한 채 재생성된다.

8. 수식 재구성 시스템

수식 영역은 일반 텍스트와 구분하여 처리된다.

다음과 같은 기호가 포함된 경우 수식으로 분류한다.

Σ

$\int$

$\sqrt{\quad}$

$\lim$

$\sin$

$\cos$

수식은 LaTeX 형식으로 변환된다.

예시:



$\int x^2 dx$

↓

`\int x^2 dx`

변환된 수식은 수식 렌더러를 통해 다시 생성된다.

9. 텍스트 제거 및 배경 복원

문서 이미지 위에 존재하는 텍스트를 제거하기 위해 단순 색상 덮어쓰기를 사용하지 않는다.

대신 주변 픽셀 정보를 활용하여 배경을 추정한다.

복원 대상은 다음과 같다.

이미지

그래프

도형
색상 배경
일러스트레이션

이를 통해 원본 시각 정보를 최대한 보존할 수 있다.

10. 번역 및 재배치

텍스트 객체는 번역 엔진으로 전달된다.

번역 이후 다음 정보를 이용하여 재배치가 수행된다.

위치
크기
색상
회전각
폰트



이를 통해 원본 문서와 유사한 시각적 구성을 유지할 수 있다.

11. 레이아웃 적응 알고리즘

번역 결과가 원본 영역을 초과하는 경우 자동 적응 알고리즘이 동작한다.

적응 방법은 다음과 같다.

글자 크기 축소
자동 줄바꿈
문자 간격 조정
텍스트 영역 재배치

이를 통해 번역 이후에도 레이아웃 붕괴를 최소화할 수 있다.

12. 구현 단계

DTRS는 다음 단계로 구현될 수 있다.

단계 1

OCR 기반 번역

단계 2

레이아웃 보존

단계 3

배경 복원



단계 4

표 재생성

단계 5

수식 재구성

단계 6

폰트 추정 인공지능

최종 단계에서는 완전한 문서 재구성형 번역 엔진을 구축한다.

13. 결론

본 연구는 OCR 기반 번역을 넘어 문서 구조 전체를 보존하는 DTRS(Document Translation and Reconstruction System)를 제안하였다.

제안된 시스템은 텍스트, 폰트, 표, 수식, 그래프 및 시각적 구조를 통합적으로 분석하여 번역 후에도 원본과 유사한 형태의 문서를 생성할 수 있다.

특히 문자 픽셀 기반 폰트 크기 추정, 문자 시작 좌표 기반 폭 복원, 구조 객체 기반 표 재생성 및 LaTeX 기반 수식 복원 기법을 통해 기존 OCR 번역 시스템의 한계를 극복할 수 있다.

향후 연구에서는 딥러닝 기반 폰트 생성 모델, 벡터 PDF 복원 기술 및 다국어 레이아웃 적응 모델을 결합하여 완전한 문서 복원형 번역 프레임워크로 발전시킬 수 있을 것으로 기대된다.





DLEGOREAM
— LABORATORY —